Phương pháp Nghiên cứu Khoa học (SC203)

Ý tưởng 2: Hệ thống tìm kiếm thông tin toán học dựa trên cấu trúc ngữ nghĩa

1. Thông tin chung

- **Môn học:** Phương pháp Nghiên cứu Khoa học (SC203 / Scientific Method)
- **Đề tài:** Xây dựng công cụ tìm kiếm và truy vấn thông tin toán học (Mathematical Information Retrieval - MathIR) dựa trên cấu trúc cây cú pháp và ngữ nghĩa công thức (LaTeX/MathML).

2. Tóm tắt Đề tài và Giả thuyết kiểm chứng (Summary và Hypotheses)

- **H1 (Chuẩn hóa ngữ nghĩa và Đổi tên biến):** Các biểu thức toán học tương đương về mặt đại số hoặc chỉ khác biệt về ký hiệu biến (ví dụ: a, b so với x, y) thường bị bỏ sót khi sử dụng phương pháp so khớp chuỗi văn bản một chiều (1D). Tuy nhiên, chúng sẽ được truy vấn chính xác khi biểu diễn dưới dạng cây ngữ nghĩa (Semantic Tree) đã chuẩn hóa.
- **H2 (Cấu trúc phân cấp và Tính chất đại số):** Biểu thức toán học mang cấu trúc cây phi tuyến với thứ tự ưu tiên của toán tử và tính chất đại số (như tính giao hoán: $a + b$ tương đương $b + a$). Việc áp dụng khoảng cách chỉnh sửa cây (Tree Edit Distance) hoặc nhúng vector đồ thị cây sẽ đạt hiệu năng tìm kiếm (Precision/Recall) vượt trội so với các phương pháp so khớp chuỗi tuần tự.
- **H3 (Kết hợp Ngữ cảnh và Công thức):** Sự kết hợp giữa vector nhúng của ngữ cảnh mô tả và biểu diễn cấu trúc của công thức toán học giúp nâng cao khả năng truy vấn bài toán gốc, ngay cả khi truy vấn của người dùng chỉ chứa một phần công thức hoặc có sự sai lệch về từ khóa.

3. Nguồn dữ liệu kiểm chứng có sẵn (Target Datasets)

Dataset chính 1: ARQMath Benchmark (CLEF Lab và DPRL Lab)

- **Nguồn cung cấp:** Document and Pattern Recognition Laboratory (DPRL - Rochester Institute of Technology) và Hội thảo đánh giá quốc tế CLEF.
- **Bản chất và Quy mô:**

    - Dữ liệu hỏi đáp toán học từ Math Stack Exchange (hơn 1.4 triệu bài đăng, câu trả lời, điểm vote, tags).
    - Hàng chục triệu công thức toán học được trích xuất thành LaTeX kèm cây thị giác (Visual Layout Tree - VLT) và cây toán tử ngữ nghĩa (Operator Tree - OPT) chuẩn MathML.
    - Bộ nhãn các cặp câu hỏi trùng lặp (duplicate questions) làm ground-truth chuẩn để đối chuẩn kết quả tìm kiếm.
- **Nhiệm vụ benchmark:** Task 1 (Answer Retrieval - Tìm câu trả lời/bài toán từ câu hỏi hỗn hợp văn bản + công thức) và Task 2 (Formula Retrieval - Tìm kiếm công thức cô lập theo cấu trúc).
- **Cách thức truy cập:** Dữ liệu mở công khai cho nghiên cứu học thuật tại kho lưu trữ của CLEF ARQMath và DPRL RIT.

Dataset chính 2: NTCIR MathIR Benchmark (NTCIR-11 và NTCIR-12)

- **Nguồn cung cấp:** Viện Tin học Quốc gia Nhật Bản (National Institute of Informatics - NII).
- **Bản chất và Quy mô:**
    - **arXiv Math Corpus:** Hàng triệu đoạn trích và bài báo toán học từ kho lưu trữ preprint arXiv.
    - **Wikipedia Math Corpus:** Hàng chục nghìn bài toán, định lý và định nghĩa trích từ Wikipedia tiếng Anh.
- **Định dạng dữ liệu:** Mã nguồn LaTeX đi kèm danh sách câu truy vấn mẫu (Evaluation Topics) có gán nhãn mức độ liên quan (Relevance Judgments) do các chuyên gia toán học thẩm định.
- **Cách thức truy cập:** Cổng học thuật NTCIR Math Task.

Dataset bổ trợ: Stack Exchange Data Dump

- **Nguồn cung cấp:** Kho lưu trữ mở Internet Archive (archive.org).
- **Bản chất và Định dạng:** Dữ liệu thô định dạng XML chứa toàn bộ bài viết, lịch sử chỉnh sửa và liên kết câu hỏi trên Math Stack Exchange.
- **Ứng dụng:** Huấn luyện các mô hình biểu diễn vector nhúng công thức toán học (tương tự kiến trúc TangentCFT).

4. Đánh giá tính khả thi và Quản lý rủi ro

- **Dung lượng và Giảm tải tính toán:** Các kho dữ liệu thô (ARQMath, MSE Dump) có kích thước lớn từ vài GB đến hàng chục GB. Nhóm áp dụng phương án trích mẫu (sampling) một tập con khoảng 50.000 – 100.000 biểu thức toán học và câu hỏi tiêu biểu để lập chỉ mục và thực nghiệm, đảm bảo phù hợp với tài nguyên máy tính cá nhân.

- **Tiền xử lý công thức:** Các dị thể cú pháp LaTeX được chuẩn hóa thông qua các thư viện chuyển đổi AST chuyên dụng (như SymPy, KaTeX AST Parser, MathML Converter).
- **Phương án dự phòng (Fallback):** Trong trường hợp gặp rào cản tài nguyên khi xử lý cây dữ liệu quy mô lớn, nhóm sẽ sử dụng trực tiếp các vector nhúng công thức đã được tiền xử lý sẵn từ benchmark MIRB và mã nguồn mở TangentCFT để kiểm chứng giả thuyết.

5. Tài liệu tham khảo

1. Mansouri, B., Rohatgi, S., Oard, D. W., Wu, J., Giles, C. L., và Zanibbi, R. (2024). Tangent-CFT và Tangent-CFTED: Combining Vector and Tree-Edit Distance Embeddings for Math Information Retrieval. arXiv:2408.11646.
2. Zanibbi, R., Mansouri, B., et al. (2020). Overview of ARQMath 2020: CLEF Lab on Answer Retrieval for Questions with Math. International Conference of the CLEF Association, LNCS 12260, 299–322.
3. Davila, K., và Zanibbi, R. (2017). Layout and Semantics: Visual Layout Trees for Mathematical Formula Retrieval. SIGIR '17.
4. Mansouri, B., et al. (2025). MIRB: A Benchmark for Mathematical Information Retrieval. arXiv:2505.15585.